



Aula 03 - Analista de Dados

UC4: Machine Learning e Data Mining

Tema: Algoritmos de Classificação (Árvores de Decisão & Regressão Logística)



Onde estamos no Machine Learning?

Relembrando o mapa do aprendizado:

1. **Supervisionado (Dados Rotulados):**
 - **Classificação** (Prever categorias: ex: Espécie da Flor, Fraude/Não Fraude). <- Foco de Hoje!
 - **Regressão** (Prever números: ex: Preço de casa, Temperatura).
2. **Não Supervisionado (Dados Sem Rótulo):**
 - **Agrupamento/Clustering** (Encontrar grupos ocultos: ex: Segmentar clientes).

1. Árvore de Decisão

- É um algoritmo de **Aprendizado Supervisionado** (pode ser usado tanto para Classificação quanto para Regressão).
- Funciona como um mapa de decisões baseadas em condições: *"Se a largura da pétala for maior que 0.8 cm, vá para a esquerda; senão, vá para a direita."*
- O objetivo é fatiar os dados em divisões cada vez mais "puras" (homogêneas).



Medindo a Pureza: 0 Índice Gini

0 índice Gini mede a "impureza" (bagunça) de um grupo de dados:

- **Gini = 0**: Nó perfeitamente puro (todos os elementos pertencem a uma única classe).
- **Gini > 0**: Nó misturado (elementos de classes diferentes).

Quanto menor o Gini, mais puras são as divisões da árvore!

A Matemática do Gini

A Fórmula (Apenas para Conhecer!)

$$Gini = 1 - \sum_{i=1}^C (p_i)^2$$

Legenda dos Termos:

- C : Número total de classes (ex: 3 no dataset Iris).
- $\sum$: Somatório (soma do cálculo de cada classe).
- p_i : Proporção (fração) de elementos da classe i no grupo.

Exemplo Prático: Aprovação de Crédito

Imagine que temos dados de 100 clientes do banco:

- 50 pagaram em dia (Aprovados).
- 50 ficaram devendo (Negados).
- Situação inicial: Gaveta bagunçada ($Gini = 0.5$).

O algoritmo precisa escolher a primeira pergunta para dividir o grupo. O que ele testa?

Testando as Perguntas (Idade vs. Salário)

- **Teste A: Idade $\leq$ 30 anos**
 - Grupo $\leq$ 30: 24 pagaram, 26 deveram (Misturado).
 - Grupo $>$ 30: 26 pagaram, 24 deveram (Misturado).
- **Teste B: Salário $\leq$ R\$ 4.000**
 - Grupo $\leq$ 4000: 3 pagaram, 42 deveram (Quase puro!).
 - Grupo $>$ 4000: 47 pagaram, 8 deveram (Quase puro!).

Vencedor: O algoritmo escolhe o **Salário** como pergunta principal porque ele reduziu mais a bagunça!



Treinando um Modelo no Scikit-Learn

O processo de treinamento segue sempre a mesma API simples:

```
# 1. Importar o algoritmo desejado
from sklearn.tree import DecisionTreeClassifier

# 2. Instanciar o modelo (criar a estrutura)
modelo = DecisionTreeClassifier(max_depth=3, random_state=42)

# 3. Treinar o modelo usando os dados de treino (X e y)
modelo.fit(X_train, y_train)
```




Fazendo Previsões

Após treinado, usamos os dados de teste (inéditos) para prever o target:

```
# 4. Gerar previsões para a base de teste
previsoes = modelo.predict(X_test)

# 5. Gerar as probabilidades estimadas (opcional)
probabilidades = modelo.predict_proba(X_test)
```



Visualizando a Árvore Graficamente

Podemos enxergar a árvore de decisão inteira para entender as regras criadas pelo modelo:

```
from sklearn.tree import plot_tree
import matplotlib.pyplot as plt

plt.figure(figsize=(12, 8))
plot_tree(
    modelo,
    feature_names=iris.feature_names,
    class_names=iris.target_names,
    filled=True
)
plt.show()
```



Desafio Prático da Aula 03

1. Carregue a partição de treino e teste do dataset Iris feita na Aula 02.
2. Instancie e treine um modelo de **Árvore de Decisão** para prever a espécie da flor (`target`).
3. Gere as previsões para a base de teste e plote a árvore graficamente.
4. Experimente com `max_depth` (1, 3 e sem limite). O que acontece com a árvore sem limite?

Conclusão

Aprendemos a treinar e prever usando o algoritmo de
Árvore de Decisão!

Próxima Aula: Como avaliar a precisão deste modelo
matematicamente? (Métricas de Avaliação).