

Aula 05 - Analista de Dados

UC4: Machine Learning e Data Mining

Tema: Métricas de Avaliação para Modelos de Classificação

Nosso Roteiro de Hoje

- Parte 1: A Matriz de Confusão (Erros e Acertos)
- Parte 2: Métricas de Avaliação (Acurácia, Precisão, Recall e F1-Score)
- Parte 3: Cenários Práticos e Consequência do Erro
- Parte 4: Hands-on: Relatório de Métricas no Python

Principais Conceitos de Hoje

Para avaliar modelos de classificação, precisamos dominar estes conceitos:

- **Matriz de Confusão:** Tabela cruzada entre previsões e dados reais.
- **Acurácia (Accuracy):** Taxa de acerto global do classificador.
- **Precisão (Precision):** Qualidade dos alarmes (evitar alarmes falsos).
- **Recall (Sensibilidade):** Capacidade de detecção (evitar omissões).
- **F1-Score:** Equilíbrio harmônico de qualidade (evitar extremos).

1. A Matriz de Confusão

Mapeia o cruzamento entre o que aconteceu na **Realidade** vs o que o **Modelo** previu:

Exemplo: Detector de Fraude em Cartão de Crédito

- **Classe Positiva (+):** Transação Fraudulenta (o evento de interesse).
- **Classe Negativa (-):** Transação Normal (o padrão).

⚠ 0 Viés do Nome: "+" e "-"

Em Machine Learning, **Positivo** não significa "bom" e **Negativo** não significa "ruim".

- **Classe Positiva (+):** É a anomalia ou o evento de interesse que queremos detectar (a agulha no palheiro).
Ex: Vírus no exame, fraude, spam, peça com defeito.
- **Classe Negativa (-):** É o estado normal ou a ausência do evento.
Ex: Paciente saudável, transação legítima, e-mail normal.



Os Acertos do Modelo

- **Verdadeiro Positivo (VP):**

O que é: Previu Positivo (+) e era Positivo (+) de verdade.

Exemplo: Ocorreu uma fraude e o modelo a bloqueou!

- **Verdadeiro Negativo (VN):**

O que é: Previu Negativo (-) e era Negativo (-) de verdade.

Exemplo: Uma compra normal foi autorizada sem problemas.



Os Erros do Modelo

- **Falso Positivo (FP) [Alarme Falso]:**
O que é: Previu Positivo (+), mas era Negativo (-) na realidade.
Exemplo: O cliente tenta comprar um pão de queijo e tem o cartão bloqueado. (Inconveniente).
- **Falso Negativo (FN) [Passou Batido]:**
O que é: Previu Negativo (-), mas era Positivo (+) na realidade.
Exemplo: Um hacker fez compras e o modelo não percebeu. (Prejuízo).



A Tabela de Confusão (Resumo)

Real \ Previsto	Previo Positivo (+)	Previo Negativo (-)
É Positivo (+)	VP <i>(Acerto do Alarme)</i>	FN <i>(Erro de Omissão)</i>
É Negativo (-)	FP <i>(Erro de Alarme Falso)</i>	VN <i>(Acerto do Normal)</i>

2. Métricas de Avaliação

Para avaliar nosso classificador além da matriz, usamos quatro métricas fundamentais:

- **Acurácia (Accuracy):** Mede a taxa geral de acerto do modelo.
- **Precisão (Precision):** Mede a qualidade do alarme (evitar alarmes falsos).
- **Recall (Sensibilidade):** Mede a capacidade de detecção (evitar omissões).
- **F1-Score:** Mede o equilíbrio harmônico entre Precisão e Recall.

Acurácia (Accuracy)

Porcentagem geral de previsões corretas do classificador.

- **Cenário:** Em 100 transações, o modelo acertou 90 normais (VN) e 5 fraudes (VP). Errou 5 vezes.
- **Fórmula e Cálculo:**

$$\text{Acurácia} = \frac{VP + VN}{\text{Total}} = \frac{5 + 90}{100} = \frac{95}{100} = 95\%$$

- **Significado:** O modelo acertou 95% do total de transações avaliadas.



Por que Acurácia pode mentir?

Imagine uma base com 990 transações normais e 10 fraudes. Se criarmos um modelo bobo que chuta "Normal" para todas as transações:

- Ele acerta 990 de 1000 transações.
- **Acurácia: 99%!**
- Mas ele detectou 0% das fraudes. A precisão e o recall para fraudes são zero! O banco vai à falência.

Precisão (Precision)

De todos os alarmes de positivo dados pelo modelo, quantos ele realmente acertou?

- **Cenário:** O modelo disparou 10 alarmes de fraude.
 - 5 eram fraudes reais (VP).
 - 5 eram compras legítimas bloqueadas por engano (FP).
- **Fórmula e Cálculo:**

$$\text{Precisão} = \frac{VP}{VP + FP} = \frac{5}{5 + 5} = \frac{5}{10} = 50\%$$

- **Significado:** Apenas metade dos alarmes dados eram de fatos reais.

Recall (Sensibilidade)

De todos os casos positivos reais que existiam, quantos o modelo conseguiu detectar?

- **Cenário:** Ocorreram 5 fraudes reais. O modelo foi agressivo e bloqueou as 5 fraudes (VP). Nenhuma escapou (FN = 0).

- **Fórmula e Cálculo:**

$$\text{Recall} = \frac{VP}{VP + FN} = \frac{5}{5 + 0} = \frac{5}{5} = 100\%$$

- **Significado:** O modelo capturou 100% de todas as fraudes que aconteceram.



F1-Score

Média harmônica que busca equilibrar Precisão e Recall em uma única nota.

- **Cenário:** No modelo acima, temos Precisão = 50% (0.5) e Recall = 100% (1.0).

- **Fórmula e Cálculo:**

$$\text{F1-Score} = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}} = 2 \times \frac{0.5 \times 1.0}{0.5 + 1.0} = 66.6\%$$

- **Significado:** A nota de equilíbrio geral do modelo foi 66.6%.

Interpretando o F1-Score (A Régua)

O F1-Score varia de 0% a 100%:

- **Alto (> 85%):** Excelente equilíbrio. Captura quase todos os casos sem dar muitos alarmes falsos. (Pronto para uso).
- **Médio (60% a 85%):** Aceitável, mas com ressalvas. Erra moderadamente em uma das frentes.
- **Baixo (< 60%):** Fraco. O modelo é ou cego (deixa passar tudo) ou paranoico (dá alarme para tudo).

Negócio: Priorizar o Recall

Na vida real, a escolha da métrica depende da **consequência do erro**:

- **Priorizar o Recall (Sensibilidade):**
Cenário: Quando um Falso Negativo (passar batido) é catastrófico.
Exemplo (Médico): É melhor dar 10 alarmes falsos (FP) do que mandar 1 paciente de câncer para casa sem tratamento (FN).
Consequência: Aceitamos precisão baixa para garantir Recall perto de 100%.



Negócio: Priorizar a Precisão

- **Priorizar a Precisão:**

Cenário: Quando um Falso Positivo (alarme falso) é inaceitável.

Exemplo (Filtro de Spam): Se um e-mail crítico de trabalho for para a caixa de spam por engano (FP), você perde negócios.

Consequência: Exigimos Precisão próxima a 100%, tolerando receber alguns spams extras (Recall menor).



Calculando Métricas no Python

```
from sklearn.metrics import confusion_matrix, classification_report

# 1. Matriz de Confusão (Realidade vs Predição)
print(confusion_matrix(y_test, y_pred))

# 2. Relatório Completo de Métricas (Precisão, Recall, F1)
print(classification_report(y_test, y_pred, target_names=iris.target_names))
```

Decifrando o Relatório (Scikit-Learn)

Além da Precisão, Recall e F1, o `classification_report()` exibe termos de rodapé essenciais:

- **Support (Suporte):** A quantidade real de amostras de cada classe na base de teste.
- **Macro Avg (Média Macro):** Média aritmética simples da métrica entre as classes (todas têm o mesmo peso, independente do tamanho).
- **Weighted Avg (Média Ponderada):** Média ponderada pela quantidade (suporte) de cada classe (reflete a proporção real dos dados).

Desafio Prático da Aula 05

1. Carregue os modelos de Árvore de Decisão (Aula 03) e KNN (Aula 04) do dataset Iris.
2. Gere a matriz de confusão e o `classification_report` para ambos os modelos.
3. Compare o desempenho dos dois modelos por espécie de flor:
 - Qual espécie teve 100% de acerto em ambos?
 - Qual modelo foi melhor nas classes mais difíceis (Versicolor/Virginica)?
4. Explique: Por que a espécie Setosa é tão fácil de classificar em comparação com as outras?

Conclusão

Agora você sabe avaliar modelos como um profissional,
olhando além da acurácia básica!

Próxima Aula: Modelagem de Regressão e Previsão de
Valores Numéricos (Regressão Linear).