

Aula 06 - Analista de Dados

UC4: Machine Learning e Data Mining

Tema: Regressão Linear com Scikit-Learn

Nosso Roteiro de Hoje

- Parte 1: O que é Regressão & Reta de Ajuste
- Parte 2: Como Medir os Erros (MSE, RMSE e R^2)
- Parte 3: Regressão Linear Múltipla
- Parte 4: Hands-on no Python: Modelando Tendências

Principais Conceitos de Hoje

Para modelar com Regressão Linear, precisamos compreender estes pilares:

- **Regressão:** Previsão de valores contínuos (números reais).
- **Equação da Reta:** Expressão matemática que define a tendência.
- **Erro Residual:** A distância entre o dado real e o valor previsto.
- **Métricas de Erro (MSE/RMSE):** Indicadores médios do desvio do modelo.
- **R^2 (R-Quadrado):** Percentual da variação explicado pelo modelo.



1. O que é Regressão?

- Ao contrário da **Classificação** (que prevê rótulos de categorias discretas), a **Regressão** prevê um **valor numérico contínuo**.
- **Exemplos de aplicação:**
 - Prever o preço de venda de um imóvel (R\$).
 - Prever o faturamento de uma empresa no mês.
 - Estimar o número de vendas baseando-se no investimento em marketing.

A Equação da Reta (Regressão Simples)

Na regressão linear simples, descrevemos a relação entre uma variável X (preditora) e uma variável Y (target) por meio de uma reta:

$$Y = aX + b$$

- b (Intercepto): Onde a reta cruza o eixo Y (quando $X = 0$).
- a (Coeficiente Angular / Inclinação): O quanto Y varia para cada acréscimo de 1 unidade em X .



Exemplo da Equação

Queremos estimar o preço de aluguel de imóveis (Y) com base na área em m^2 (X). O modelo encontrou:

$$\text{Preço} = 30 \times \text{Área} + 500$$

- Se o imóvel tem $0 m^2$, o preço de partida é R\$ 500 (b).
- Para cada $1 m^2$ adicionado, o aluguel sobe R\$ 30 (a).
- Um imóvel de $100 m^2$ custará:

$$\text{Preço} = 30 \times 100 + 500 = 3500$$

Erro Residual

Nenhum modelo é perfeito. A diferença entre a realidade e o modelo é o **Resíduo (Erro)**:

$$\text{Erro} = Y_{\text{real}} - Y_{\text{previsto}}$$

- **Exemplo Real:**

- Um apartamento custa de verdade R\$ 3.800 (Y_{real}).
- O modelo calculou que deveria custar R\$ 3.500 (Y_{previsto}).
- O **Erro Residual** deste ponto foi de **+R\$ 300**.

Mínimos Quadrados Ordinários (OLS)


OLS significa *Ordinary Least Squares* (Mínimos Quadrados Ordinários).

Como a reta ideal é encontrada matematicamente por este método?

- O algoritmo calcula o erro para todos os pontos da base de treino.
- Ele ajusta a reta (coeficientes a e b) para **minimizar a soma de todos os erros elevados ao quadrado**.
- O quadrado evita que erros positivos e negativos se cancelem mutuamente.

▴ 2. Como medir o erro geral do modelo?

- **MSE (Erro Quadrático Médio):** Média dos desvios elevados ao quadrado. Penaliza severamente erros maiores.
- **RMSE (Raiz do Erro Quadrático Médio):** Traz o erro de volta para a mesma escala dos dados reais (ex: R\$ ou metros).
- **R^2 (Coeficiente de Determinação):** Mede a qualidade do ajuste. Indica a porcentagem de variação dos dados que o modelo explica.



Fórmulas Matemáticas

O cálculo do desvio acumulado é representado por:

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$RMSE = \sqrt{MSE}$$

- Y_i : Valor Real do ponto i .
- $\hat{Y}_i$: Valor Previsto pela reta para o ponto i .
- n : Quantidade total de pontos de teste.

12 34 Exemplo Prático: MSE e RMSE

Imaginemos 3 apartamentos na base de teste ($n = 3$):

Y (Real)	$\hat{Y}$ (Previsto)	Erro ($Y - \hat{Y}$)	Erro ao Quadrado
R\$ 100	R\$ 110	-10	100
R\$ 200	R\$ 190	+10	100
R\$ 300	R\$ 320	-20	400

- Soma dos Quadrados: $100 + 100 + 400 = 600$
- MSE: $\frac{600}{3} = 200$
- RMSE: $\sqrt{200} \approx \text{R\$ } 14,14$

O que significa o R^2 (R-Quadrado)?

Mede a performance comparando nosso modelo com um modelo "chutador de média" (que prevê $\bar{Y}$ para todos):

$$R^2 = 1 - \frac{SQR}{SQT} = 1 - \frac{\sum (Y_i - \hat{Y}_i)^2}{\sum (Y_i - \bar{Y})^2}$$

- **SQR (Soma dos Quadrados dos Resíduos):** O desvio/erro acumulado da nossa reta predita.
- **SQT (Soma dos Quadrados Totais):** A variabilidade total dos dados em relação à média ($\bar{Y}$).

Interpretando o R^2

Como avaliar o valor do coeficiente de determinação?

- **Linha de Base (SQT):** Representa o erro total se usássemos apenas a média ($\bar{Y}$) como "chute" fixo para todos os pontos.
- **Reta Perfeita:** Se o modelo predisser tudo corretamente, teremos $SQR = 0 \implies R^2 = 1$ (100% da variabilidade explicada).
- **Modelo Igual à Média:** Se a reta for tão imprecisa quanto a média, $SQR = SQT \implies R^2 = 0$.



3. Regressão Linear Múltipla

E se quisermos prever o valor usando várias colunas preditoras (ex: área, número de quartos e vagas de garagem)?

A lógica é idêntica, mas a reta passa a ser um plano ou hiperplano multidimensional:

$$Y = a_1X_1 + a_2X_2 + a_3X_3 + \dots + b$$

- O modelo calcula um coeficiente angular (a_n) diferente para cada coluna, isolando o peso individual de cada feature!



Regressão Linear com Scikit-Learn

```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# 1. Instanciar e treinar o modelo
modelo = LinearRegression()
modelo.fit(X_train, y_train)

# 2. Prever na base de teste
y_pred = modelo.predict(X_test)

# 3. Extrair métricas de desempenho
r2 = r2_score(y_test, y_pred)
mse = mean_squared_error(y_test, y_pred)
```

Extraindo os Coeficientes Gerados

Podemos inspecionar a fórmula exata criada pelo Scikit-Learn usando os atributos que terminam com `_`:

```
# Coeficiente angular 'a' (ou lista de coeficientes na múltipla)
print("Coeficientes (a):", modelo.coef_)

# Intercepto 'b'
print("Intercepto (b):", modelo.intercept_)
```




Desafio Prático da Aula 06

1. Carregue o gerador individual de vendas no Jupyter.
2. Divida os dados em treino e teste (80/20).
3. Treine uma Regressão Linear Simples (Marketing vs Vendas).
4. Descubra os coeficientes e plote a reta de regressão.
5. Calcule o R^2 e o MSE no conjunto de teste.
6. Adicione uma segunda variável (ex: cliques) e veja se o R^2 aumenta!

Conclusão

Agora você sabe como modelar e prever tendências contínuas usando Regressão Linear no Python!